



Tarea 2

Problema 1: Ruido Poisson y filtrado Gaussiano adaptativo

Marco Teórico y Fundamentos Matemáticos

1. Modelo de ruido Poisson y dependencia de la intensidad

El ruido de Poisson representa el comportamiento del conteo de fotones que llegan a un sensor óptico. Considerando una imagen ideal $x(k, l) \in [0, 1]$, al multiplicarla por un factor N obtenemos el número promedio esperado de conteos por píxel. Entonces, la variable aleatoria K sigue una distribución de Poisson:

$$K \sim \text{Poisson}(Nx(k, l))$$

Por definición, la esperanza y la varianza de una variable aleatoria con distribución de Poisson son iguales:

$$\mathbb{E}[K] = \text{Var}(K) = Nx(k, l)$$

Normalizando la imagen observada mediante $y(k, l) = \frac{K}{N}$, obtenemos:

$$\mathbb{E}[y(k, l)] = x(k, l)$$

$$\begin{aligned}\sigma_y^2(k, l) &= \text{Var}\left(\frac{K}{N}\right) \\ &= \frac{1}{N^2} \text{Var}(K) \\ &= \frac{x(k, l)}{N}\end{aligned}$$

De esta manera, la varianza del ruido depende directamente de la intensidad de la imagen. Con $N = 40$, obtenemos los siguientes valores teóricos:

- **Fondo** ($I = 0.15$):

$$\sigma_{\text{fondo}}^2 = \frac{0.15}{40} = 0.00375$$

$$\sigma_{\text{fondo}} \approx 0.0612$$

- **Cuadrado** ($I = 0.45$):

$$\sigma_{\text{cuadrado}}^2 = \frac{0.45}{40} = 0.01125$$

$$\sigma_{\text{cuadrado}} \approx 0.1061$$

- **Círculo** ($I = 0.80$):

$$\sigma_{\text{círculo}}^2 = \frac{0.80}{40} = 0.02000$$

$$\sigma_{\text{círculo}} \approx 0.1414$$

Entonces, las regiones más brillantes presentan una mayor varianza del ruido. Sin embargo, como veremos en la experimentación, el parámetro de suavizado óptimo no depende únicamente de esta varianza, ya que la geometría de las regiones y la proporción de píxeles cercanos a sus fronteras también influyen en el error final.

2. Construcción del kernel Gaussiano isotrópico y elección del soporte

Un kernel Gaussiano continuo en $\mathbb{R}^2$ está definido por:

$$g(u, v; \sigma) = \exp\left(-\frac{u^2 + v^2}{2\sigma^2}\right)$$

Para aplicarlo a imágenes discretas, definimos un soporte finito truncando la función en un radio:

$$r = \lceil 3\sigma \rceil$$

El tamaño total del kernel resultante es:

$$(2r + 1) \times (2r + 1)$$

Esta elección permite conservar aproximadamente el 98.89% de la masa de una distribución Gaussiana bidimensional isotrópica dentro de un radio de 3σ . El porcentaje exacto puede variar ligeramente al discretizar y truncar el kernel.

Posteriormente, los coeficientes $h[m, n]$ se normalizan:

$$h_{\text{norm}}[m, n] = \frac{h[m, n]}{\sum_{m'=-r}^r \sum_{n'=-r}^r h[m', n']}$$

Esta normalización asegura que la suma de los coeficientes sea igual a uno:

$$\sum_{m=-r}^r \sum_{n=-r}^r h_{\text{norm}}[m, n] = 1$$

De este modo, al filtrar una región homogénea plana, la intensidad se conserva y no se altera el brillo general de la imagen.

3. Estimación local y filtrado espacialmente adaptativo

Para construir un filtro adaptativo dependiente de la posición, primero estimamos la intensidad subyacente $\hat{\mu}(x, y)$ aplicando un filtro Gaussiano auxiliar con $\sigma_{\text{aux}} = 1.0$.

Esta estimación permite reducir las fluctuaciones producidas por el ruido antes de decidir qué parámetro de suavizado utilizar en cada píxel. Para ruido aproximadamente independiente y de varianza local constante, la desviación estándar después de un suavizado Gaussiano se puede aproximar mediante:

$$\sigma_{\text{ruido, suavizado}} \approx \sigma_{\text{ruido}} \sqrt{\sum_{m,n} h[m, n]^2}$$

En el caso continuo, para un kernel Gaussiano normalizado y una región suficientemente grande, esta expresión se aproxima por:

$$\sigma_{\text{ruido, suavizado}} \approx \frac{\sigma_{\text{ruido}}}{2\sqrt{\pi} \sigma_{\text{aux}}}$$

Esta aproximación permite entender por qué el pre-suavizado facilita la estimación de la intensidad. Sin embargo, la incertidumbre exacta depende también de la discretización del kernel y de las características locales de la imagen.

Para evitar saltos abruptos en las fronteras, el mapa paramétrico $\sigma(x, y)$ se define mediante una interpolación lineal continua de $\hat{\mu}(x, y)$ entre las intensidades ideales de las tres regiones y sus respectivos parámetros óptimos.

Utilizando los valores experimentales obtenidos, podemos expresar esta relación como:

$$\sigma(x, y) = F(\hat{\mu}(x, y))$$

donde la función F interpola los siguientes puntos:

$$(0.15, 1.75), \quad (0.45, 1.35), \quad (0.80, 1.45)$$

Finalmente, la imagen se filtra utilizando un kernel cuyo parámetro depende de la posición:

$$y_{\text{adapt}}[i, j] = \sum_{m=-r(i,j)}^{r(i,j)} \sum_{n=-r(i,j)}^{r(i,j)} y[i-m, j-n] \cdot h_{\sigma(i,j)}[m, n]$$

donde $r(i, j) = \lceil 3\sigma(i, j) \rceil$. Entonces, cada píxel utiliza un kernel cuyo tamaño y grado de suavizado dependen de la intensidad estimada en su entorno.

Preguntas Guiadas

1. ¿Por qué la varianza del ruido Poisson depende de la intensidad? Relacione esta propiedad con las diferencias observadas entre las tres curvas RMSE(σ).

Como se demostró, la varianza del ruido Poisson es proporcional a la intensidad subyacente:

$$\sigma_y^2 = \frac{x}{N}$$

A partir de esto, podemos observar que las regiones más brillantes presentan una mayor varianza. A simple vista, uno podría esperar que el parámetro de suavizado óptimo aumentara de manera monótona con la varianza. Sin embargo, los resultados experimentales muestran que el Fondo ($I = 0.15$) requiere el mayor suavizado ($\sigma^* = 1.75$), seguido por el Círculo ($\sigma^* = 1.45$) y el Cuadrado ($\sigma^* = 1.35$).

Esta diferencia se puede explicar considerando tanto la intensidad de cada región como la proporción de píxeles cercanos a sus fronteras. El Fondo presenta una gran extensión homogénea, por lo que una parte importante de sus píxeles puede suavizarse sin mezclar intensidades de regiones diferentes. En cambio, el Cuadrado corresponde a un anillo de 128×128 píxeles con un hueco interno de radio 32, por lo que posee fronteras internas y externas que pueden verse afectadas por el suavizado.

Entonces, al aumentar σ , se reduce la varianza del ruido, pero también aumenta la posibilidad de mezclar intensidades a través de las fronteras. El valor óptimo representa un equilibrio entre ambos efectos. En el caso del Círculo, su mayor varianza de ruido puede justificar que el parámetro óptimo sea ligeramente superior al del Cuadrado, aunque esto depende de la geometría y de la máscara utilizada para calcular el RMSE.

2. ¿Por qué se pidió incluir en las máscaras los píxeles próximos a los bordes? ¿Qué ocurriría con el σ óptimo si el RMSE se midiera sólo en una pequeña zona plana muy alejada de cualquier frontera?

La inclusión de píxeles próximos a las fronteras obliga al RMSE a penalizar el difuminado de los bordes. El filtro Gaussiano reduce la varianza local promediando los valores de un vecindario. Sin embargo, si este vecindario cruza una frontera, se mezclan intensidades diferentes y aparece un error adicional.

Ahora, si el RMSE se calculara únicamente en una región plana suficientemente alejada de cualquier frontera, el comportamiento sería distinto. En ese caso, aumentar σ reduciría progresivamente la influencia del ruido, por lo que el parámetro óptimo tendería a ser mayor que el obtenido al considerar toda la región, incluyendo sus bordes.

Sin embargo, no podemos afirmar que el RMSE necesariamente decrezca de forma estrictamente monótona hasta cero cuando $\sigma \rightarrow \infty$. En una imagen finita, el comportamiento depende de las condiciones de borde del filtro y de si el vecindario termina incorporando píxeles de otras regiones. Por lo tanto, la conclusión es que excluir los bordes favorece valores mayores de σ , pero no garantiza que un suavizado infinito sea óptimo.

3. ¿Cómo determina el tamaño del kernel a partir de σ y por qué es necesario normalizar sus coeficientes?

El radio del kernel se determina mediante la expresión:

$$r = \lceil 3\sigma \rceil$$

Por lo tanto, su tamaño total es:

$$(2r + 1) \times (2r + 1)$$

Esto permite conservar la mayor parte de la masa del kernel Gaussiano, descartando las contribuciones más alejadas del centro.

Luego, normalizamos los coeficientes para que su suma sea igual a uno:

$$\sum_{m=-r}^r \sum_{n=-r}^r h_{\text{norm}}[m, n] = 1$$

Esta normalización es necesaria para conservar la intensidad de una región homogénea. Si no normalizamos los coeficientes, la suma de los valores del kernel dependería de su truncamiento y podría introducir cambios artificiales en el brillo de la imagen.

4. Explique exactamente cómo obtiene $\hat{\mu}(x, y)$ y cómo transforma ese valor en $\sigma(x, y)$. Seleccione un píxel de cada una de las tres regiones e indique $\hat{\mu}$, σ y el kernel aplicado.

La estimación $\hat{\mu}(x, y)$ se obtiene aplicando un filtro Gaussiano a la imagen ruidosa, utilizando $\sigma_{\text{aux}} = 1.0$. Luego, este valor se transforma en $\sigma(x, y)$ mediante una interpolación lineal continua implementada con `np.interp`, utilizando las intensidades ideales:

$$x_{\text{nodos}} = [0.15, 0.45, 0.80]$$

y los respectivos parámetros óptimos:

$$\sigma_{\text{nodos}} = [1.75, 1.35, 1.45]$$

A partir de esto, evaluamos los siguientes píxeles:

- **Fondo, píxel (10, 10):**

La intensidad estimada es $\hat{\mu} = 0.150$, por lo que:

$$\sigma(10, 10) = 1.750$$

El radio del kernel es $r = \lceil 3(1.75) \rceil = 6$, por lo que su tamaño es 13×13 . El coeficiente central es aproximadamente 0.0520 y la suma de los coeficientes normalizados es 1.

- **Cuadrado, píxel (100, 100):**

La intensidad estimada es $\hat{\mu} = 0.472$. Al interpolar entre los nodos correspondientes, obtenemos:

$$\sigma(100, 100) \approx 1.356$$

El radio del kernel es $r = \lceil 3(1.356) \rceil = 5$, por lo que su tamaño es 11×11 . El coeficiente central es aproximadamente 0.0865 y la suma de los coeficientes normalizados es 1.

- **Círculo, píxel (128, 128):**

La intensidad estimada es $\hat{\mu} = 0.795$, lo que entrega:

$$\sigma(128, 128) \approx 1.449$$

El radio del kernel es $r = \lceil 3(1.449) \rceil = 5$, por lo que su tamaño es 11×11 . El coeficiente central es aproximadamente 0.0759 y la suma de los coeficientes normalizados es 1.

- **Cerca de la frontera entre el Cuadrado y el Círculo, píxel (128, 159):**

La intensidad estimada es $\hat{\mu} = 0.648$, por lo que:

$$\sigma(128, 159) \approx 1.406$$

El radio del kernel es $r = \lceil 3(1.406) \rceil = 5$, por lo que su tamaño es 11×11 . El coeficiente central es aproximadamente 0.0805 y la suma de los coeficientes normalizados es 1.

Entonces, podemos observar que el parámetro σ cambia de acuerdo con la intensidad estimada, permitiendo adaptar el grado de suavizado a cada región. Los tamaños y coeficientes indicados corresponden a los resultados experimentales entregados.

5. ¿Por qué el filtro espacialmente adaptativo no puede escribirse, en general, como una única convolución con un kernel fijo? ¿Se podría aproximar de otra manera?

La convolución estándar utiliza el mismo kernel en todas las posiciones de la imagen. Es decir, el operador es invariante frente a traslaciones, suponiendo condiciones de borde compatibles.

En nuestro método, en cambio, el parámetro $\sigma(x, y)$ depende de la intensidad estimada $\hat{\mu}(x, y)$, que a su vez depende de la imagen de entrada. Por lo tanto, el kernel cambia según la posición y el filtro es espacialmente variante. Además, como la selección del kernel depende de la propia imagen, el operador completo es, en general, no lineal.

Una forma de aproximar este procedimiento consiste en filtrar la imagen completa con varios kernels Gaussianos fijos, por ejemplo, con $\sigma \in \{1.35, 1.45, 1.75\}$, y después combinar los resultados píxel a píxel mediante pesos obtenidos a partir de $\hat{\mu}(x, y)$. De esta forma, podemos aproximar el comportamiento adaptativo utilizando convoluciones estándar, que suelen ser más eficientes computacionalmente.

6. Compare cuantitativamente el mejor Gaussiano global y su versión adaptativa. ¿En qué regiones gana o pierde cada uno y qué mecanismo explica esas diferencias?

El mejor filtro Gaussiano global, utilizando $\sigma = 1.50$, obtiene un RMSE de 0.02381. En cambio, el filtro adaptativo continuo obtiene un RMSE de 0.02364.

La mejora relativa del RMSE es:

$$\text{Mejora} = \frac{0.02381 - 0.02364}{0.02381} \times 100 \approx 0.71\%$$

Por lo tanto, el filtro adaptativo presenta una mejora global pequeña, pero positiva, respecto del Gaussiano global.




Figure 1: Perfil Horizontal

Al analizar las fronteras, el uso de una función continua $F(\hat{\mu})$ permite evitar los saltos abruptos en el parámetro $\sigma(x, y)$ que aparecerían al utilizar umbrales duros. Esto ayuda a reducir los cambios bruscos en el grado de suavizado entre regiones vecinas.

Sin embargo, una interpolación continua no elimina necesariamente todos los halos, ya que estos también dependen de la mezcla de intensidades producida por el filtro cerca de las fronteras.

Finalmente, la mejora global es relativamente pequeña porque los parámetros óptimos de las tres regiones no difieren demasiado entre sí, variando entre 1.35 y 1.75. Además, si las curvas $\text{RMSE}(\sigma)$ son relativamente planas cerca de sus mínimos, utilizar un parámetro distinto para cada región puede producir una mejora acotada.

PROBLEMA 2: DIFUSIÓN ANISOTRÓPICA Y VARIACIÓN TOTAL

1. Criterio de Estabilidad y Variación Total (TV)

El esquema explícito de diferencias finitas está regido por la condición CFL para 4 vecinos:

$$4\Delta t c_{\max} \leq 1$$

En el modelo original de Variación Total, el coeficiente de difusión está definido como:

$$c_{TV} = \frac{1}{\sqrt{|\nabla u|^2 + \epsilon^2}}$$

Por lo tanto, el valor máximo de este coeficiente está acotado por:

$$c_{\max} = \frac{1}{\epsilon}$$

Si utilizamos $\epsilon = 0.01$, obtenemos que $c_{\max} = 100$. Entonces, para cumplir con la condición de estabilidad, debemos tener:

$$4\Delta t \cdot 100 \leq 1$$

Despejando Δt , obtenemos que:

$$\Delta t \leq 0.0025$$

Este valor es bastante pequeño, por lo que se requieren muchas iteraciones para completar el proceso de difusión.

Para resolver esto y poder utilizar un paso temporal de $\Delta t = 0.20$, normalizamos el coeficiente de difusión de la siguiente manera:

$$c_{TV, \text{norm}} = \frac{\epsilon}{\sqrt{|\nabla u|^2 + \epsilon^2}}$$

Al multiplicar el coeficiente original por ϵ , obtenemos un coeficiente cuyo valor máximo es $c_{\max} = 1$. De esta manera, la condición de estabilidad queda expresada como:

$$4\Delta t \leq 1$$

Por lo tanto, podemos utilizar $\Delta t = 0.20$ sin superar el límite de estabilidad establecido por esta condición.

Respecto al valor de ϵ , podemos observar que cuando utilizamos un valor pequeño, como 10^{-4} , el modelo distingue mejor los bordes, pero la difusión en las zonas homogéneas puede ser demasiado lenta. En este caso, se requieren más de 200 iteraciones para limpiar el ruido, obteniendo un RMSE aproximado de 0.035.

En cambio, si aumentamos ϵ a 0.1 o 0.5, el coeficiente de difusión se vuelve más uniforme en la imagen, acercándose a un comportamiento de difusión lineal. Esto provoca que los bordes se suavicen rápidamente y que el RMSE aumente por encima de 0.070.

2. Propuestas de Coeficientes Alternativos

Propuesta 1: Coeficiente de Catté et al. con decaimiento abrupto

Proponemos utilizar el siguiente coeficiente de difusión:

$$c = \frac{1}{1 + \left(\frac{|\nabla u_\sigma|}{k}\right)^4}$$

En este caso, utilizamos un pre-suavizado gaussiano ligero, con $\sigma = 0.5$, para calcular el gradiente. De esta manera, se busca evitar que el ruido detenga la difusión antes de tiempo.

Además, el exponente 4 provoca que el coeficiente disminuya más rápidamente cuando el gradiente supera el umbral k . Es por esto que se espera una mejor preservación de los bordes en comparación con la formulación clásica de Perona-Malik.

- **Fortaleza:** Permite preservar mejor los bordes nítidos debido a la caída más abrupta del coeficiente de difusión.
- **Debilidad:** Puede generar el efecto escalera (*staircasing*), especialmente en regiones donde la intensidad cambia de manera suave.

Propuesta 2: Coeficiente basado en el gradiente y el Laplaciano

Otra alternativa consiste en utilizar tanto el gradiente como el Laplaciano para definir el coeficiente de difusión. Para esto, definimos:

$$E = \frac{|\nabla u_\sigma|}{k_{\text{grad}}} + \frac{|\nabla^2 u_\sigma|}{k_{\text{lap}}}$$


A partir de esto, obtenemos el coeficiente:

$$c = \exp(-E)$$

La principal ventaja de esta propuesta es que el Laplaciano entrega información sobre los cambios del gradiente. Por ejemplo, una rampa de intensidad suave puede presentar un gradiente constante relativamente alto, lo que podría reducir la difusión si utilizamos solamente el gradiente. Sin embargo, en esta región el Laplaciano es aproximadamente cero.

En cambio, cerca de un borde verdadero, el Laplaciano puede presentar valores elevados a ambos lados del borde y un cruce por cero en sus proximidades. De esta manera, se incorpora información adicional para distinguir entre bordes y variaciones suaves de intensidad.

- **Fortaleza:** Permite distinguir mejor los bordes de ciertas variaciones suaves de iluminación al considerar información del gradiente y del Laplaciano.
- **Debilidad:** Es muy sensible al ruido, ya que el cálculo del Laplaciano amplifica las variaciones de alta frecuencia.



3. Sensibilidad del Laplaciano y Pre-suavizado

Para justificar el uso de un pre-suavizado con $\sigma_{\text{pre}} = 0.8$, analizamos el efecto que tiene el ruido sobre el cálculo del Laplaciano.

En un Laplaciano discreto de 5 puntos, definido como:

$$\nabla^2 u_{i,j} = u_{i+1,j} + u_{i-1,j} + u_{i,j+1} + u_{i,j-1} - 4u_{i,j}$$

Si consideramos ruido independiente en cada píxel, con varianza σ^2 , la varianza del ruido en esta estimación se multiplica por:

$$1^2 + 1^2 + 1^2 + 1^2 + (-4)^2 = 20$$

Por lo tanto, la desviación estándar del ruido en el Laplaciano queda dada por:

$$\sigma_{\nabla^2 u} = \sqrt{20} \sigma$$

Considerando que la desviación estándar del ruido original es $\sigma = 0.05$, obtenemos que:

$$\sigma_{\nabla^2 u} = \sqrt{20} \cdot 0.05 \approx 0.2236$$

Este valor es considerablemente mayor que la constante $k_{\text{lap}} = 0.04$. Por lo tanto, si calculamos el Laplaciano directamente sobre la imagen con ruido, el indicador E puede tomar valores elevados incluso en regiones homogéneas.

Como el coeficiente de difusión está definido como $c = \exp(-E)$, cuando E aumenta, el coeficiente disminuye y se acerca a cero. Es por esto que, sin un pre-suavizado, el ruido puede detener la difusión en zonas donde todavía es necesario suavizar la imagen.

Para evitar este comportamiento, utilizamos un filtro gaussiano antes de calcular el Laplaciano. De esta manera, reducimos la influencia del ruido y obtenemos una estimación más estable de los cambios de intensidad.

4. Experimento 2: Inestabilidad vs. Sobre-suavizado

Para analizar ambos casos y distinguir sus efectos, utilizamos la Propuesta 1 con $k = 0.08$.

Caso A: Inestabilidad

En este caso, fijamos el paso temporal en $\Delta t = 0.35$. Al reemplazar este valor en la condición CFL, obtenemos:

$$4\Delta t c_{\max} = 4 \cdot 0.35 \cdot 1 = 1.4$$

Como:

$$1.4 > 1$$

No se cumple la condición de estabilidad del esquema explícito. Por lo tanto, el proceso puede volverse numéricamente inestable y presentar oscilaciones que aumentan a medida que avanzan las iteraciones.

En este caso, después de solamente 20 iteraciones, aparecen oscilaciones con un patrón similar a un tablero de ajedrez y el RMSE supera el valor de 0.100.

Caso B: Sobre-suavizado

En este caso, utilizamos $\Delta t = 0.20$, cumpliendo con la condición de estabilidad, pero aumentamos el número de iteraciones a 150.

A diferencia del caso anterior, aquí no se espera una divergencia numérica debido al paso temporal. Sin embargo, al aplicar demasiadas iteraciones, la difusión puede eliminar detalles y texturas que son importantes para representar la imagen original.

Es por esto que, aunque el algoritmo se mantiene numéricamente estable, el RMSE puede aumentar progresivamente respecto a la imagen original. Esto muestra que cumplir con la condición de estabilidad no garantiza que el resultado final sea el más adecuado.

5. Preguntas Guiadas

a) ¿En qué momento de cada iteración se calculan el gradiente, el Laplaciano y el coeficiente de difusión c ?

El gradiente, el Laplaciano y el coeficiente de difusión se calculan al inicio de cada iteración temporal, utilizando la imagen correspondiente al estado actual u_t .

Entonces, una vez calculados estos valores, se utilizan para obtener los flujos en las cuatro direcciones: norte, sur, este y oeste. Finalmente, con estos flujos se actualiza la imagen para obtener el siguiente estado u_{t+1} .

Este procedimiento se puede observar en las primeras líneas de la función `anisotropic_diffusion_step`, donde se calculan los coeficientes antes de realizar la actualización de la imagen.

b) Seleccione un píxel dentro de una región homogénea y otro próximo a un borde. Muestre las diferencias direccionales, c y la actualización en una iteración.

Para analizar el comportamiento espacial del algoritmo, evaluamos la Propuesta 1 durante la primera iteración. Respecto a la convergencia de los modelos, podemos observar que la Propuesta 1 alcanza su mejor resultado rápidamente, con un RMSE mínimo de 0.0284 en la iteración 3. En cambio, el modelo de Variación Total alcanza un RMSE de 0.0274 en la iteración 7 y la Propuesta 2 obtiene un RMSE de 0.0276 en la iteración 5.

A partir de esto, comparamos las diferencias direccionales, los coeficientes de difusión y la actualización del píxel en dos ubicaciones representativas de la imagen.

Píxel en una región homogénea (50, 50):

En esta ubicación, el píxel presenta una intensidad inicial de $u_t = 0.7040$. Las diferencias de intensidad con sus vecinos son las siguientes:

$$\begin{aligned} N &= 0.1597, & S &= 0.1198, \\ E &= 0.1292, & W &= 0.1195. \end{aligned}$$

Podemos observar que todas las diferencias son positivas, lo que indica que los vecinos presentan una intensidad mayor que la del píxel seleccionado. Como se encuentra en una región homogénea, las variaciones se asocian principalmente al ruido presente en la imagen.

En este caso, el indicador de borde se mantiene bajo, permitiendo que el coeficiente de difusión central alcance un valor elevado de $c = 0.9880$. Los coeficientes de difusión en las cuatro direcciones también presentan valores relativamente altos:

$$\begin{aligned} c_N &= 0.8064, & c_S &= 0.8825, \\ c_E &= 0.8938, & c_W &= 0.7836. \end{aligned}$$

Entonces, el algoritmo permite que exista una mayor difusión entre el píxel y sus vecinos, modificando su intensidad durante la iteración. Finalmente, el valor se actualiza a:

$$u_{t+1} = 0.7927$$

Esto muestra cómo el algoritmo suaviza el ruido en las regiones homogéneas, modificando la intensidad de los píxeles para reducir las variaciones locales.

Píxel cercano a un borde (100,150):

En cambio, para el píxel ubicado cerca de un borde, la intensidad inicial es $u_t = 0.8338$. Las diferencias direccionales obtenidas son:

$$\begin{aligned} N &= -0.0150, & S &= 0.0430, \\ E &= -0.0865, & W &= 0.0148. \end{aligned}$$

Podemos observar que las diferencias presentan signos distintos y magnitudes diferentes, lo que refleja una mayor variación de intensidad entre el píxel y sus vecinos.

En este caso, el coeficiente de difusión central disminuye a $c = 0.8276$. Por otra parte, los coeficientes correspondientes a las cuatro direcciones son:

$$\begin{aligned} c_N &= 0.8808, & c_S &= 0.8914, \\ c_E &= 0.8470, & c_W &= 0.8884. \end{aligned}$$

A partir de estos valores, podemos observar que la difusión se reduce en las direcciones donde el modelo detecta mayores variaciones de intensidad. Sin embargo, los coeficientes siguen siendo relativamente altos, por lo que no se bloquea completamente el flujo entre los píxeles.

Finalmente, después de una iteración, obtenemos:

$$u_{t+1} = 0.8269$$

Como el valor inicial era $u_t = 0.8338$, el cambio de intensidad es:

$$\Delta u = u_{t+1} - u_t = 0.8269 - 0.8338 = -0.0069$$

Por lo tanto, el píxel presenta una variación pequeña durante la iteración. Esto muestra cómo la difusión anisotrópica permite suavizar la imagen sin modificar excesivamente las intensidades cercanas a los bordes, contribuyendo a preservar sus características principales.